LAPORAN PROJECT SEDERHANA ARX

DENGAN METRIX L-DIVERSITY DAN K-ANONYMITY

DISUSUN OLEH :

1. **AURA AULIA A.H.P. – 1206230003**
2. **M.FERY ARDIANSYAH – 1206230044**

PROGRAM STUDI SAINS DATA

FAKULTAS INFORMATIKA

TELKOM UNIVERSITY SURABAYA

DAFTAR ISI

1. Pendahuluan.....2
2. Metodologi.....4
   2.1 L-Diversity 4
   2.2 K-Anonymity 7
3. Hasil dan Analisis 8
   3.1 Hasil dan Analisis Penerapan L-Diversity 8
   3.2 Hasil dan Analisis Penerapan K-Anonymity 9
4. Perbandingan l-Diversity dan k-Anonymity.....11
5. Kesimpulan 13

1. Pendahuluan

Pada penelitian ini dilakukan evaluasi privasi terhadap dataset *Bank Marketing* menggunakan dua metrik privasi, yaitu l-diversity dan k-anonymity. Kedua metrik ini digunakan untuk memastikan bahwa data tetap melindungi identitas individu meskipun informasi yang bersifat sensitif masih dipertahankan untuk tujuan analisis. Fokus utama pada tahap awal ini adalah penerapan l-diversity, sedangkan penerapan k-anonymity dilakukan pada tahap berikutnya untuk kemudian dibandingkan hasilnya.

Dataset yang digunakan merupakan data bank berisi informasi demografis dan historis interaksi pelanggan dengan layanan pemasaran bank. Dari keseluruhan atribut, beberapa dipilih sebagai quasi-identifier, yaitu atribut yang berpotensi digunakan untuk mengidentifikasi individu apabila digabungkan. Atribut tersebut antara lain: *age, job, marital, education, housing, loan, contact, day, month, duration, campaign, pdays, previous,* dan *poutcome*. Berikut untuk gambaran dari dataset awal.

Input data

	age	job	marital	education	default	balance
1	59	admin.	married	secondary	no	2343
2	56	admin.	married	secondary	no	45
3	41	technician	married	secondary	no	1270
4	55	services	married	secondary	no	2476
5	54	admin.	married	tertiary	no	184
6	42	management	single	tertiary	no	0
7	56	management	married	tertiary	no	830
8	60	retired	divorced	secondary	no	545
9	37	technician	married	secondary	no	1
10	28	services	single	secondary	no	5090
11	38	admin.	single	secondary	no	100
12	30	blue-collar	married	secondary	no	309
13	29	management	married	tertiary	no	199
14	46	blue-collar	single	tertiary	no	460
15	31	technician	single	tertiary	no	703
16	35	management	divorced	tertiary	no	3837
17	32	blue-collar	single	primary	no	611
18	49	services	married	secondary	no	-8
19	41	admin.	married	secondary	no	55
20	49	admin.	divorced	secondary	no	168
21	28	admin.	divorced	secondary	no	785
22	43	management	single	tertiary	no	2067
23	43	management	divorced	tertiary	no	388
24	43	blue-collar	married	primary	no	-192
25	37	unemployed	single	secondary	no	381

Gambar 1.1. Data Awal

Selain itu terdapat tiga atribut yang didefinisikan sebagai atribut sensitif, yaitu *deposit*, *balance*, dan *default*. Ketiga atribut ini dianggap penting untuk dilindungi karena berisi informasi finansial yang dapat menimbulkan risiko apabila sampai terhubung dengan identitas seseorang.

Beberapa atribut quasi-identifier tidak memiliki *hierarchy generalization* karena sifat datanya tidak memungkinkan disusun dalam bentuk hirarki tanpa menghilangkan makna (misalnya *duration, campaign, previous*). Namun ARX tetap memperlakukan atribut tersebut sebagai QI tanpa generalisasi apabila memang tidak disediakan hierarchy-nya.

Pendekatan awal analisis memfokuskan pada metrik l-diversity karena model ini tidak hanya menuntut bahwa satu kelompok data cukup banyak anggotanya, tetapi juga memastikan bahwa nilai atribut sensitif di dalam kelompok tersebut cukup bervariasi. Hal ini melindungi data dari *homogeneity attack* dan *background knowledge attack* yang sering kali tidak teratasi oleh k-anonymity saja.

2. Metodologi

2.1 L-Diversity

Proses anonimasi dilakukan menggunakan perangkat lunak ARX Data Anonymization Tool. Pada tahap penerapan l-diversity, model yang digunakan adalah Distinct l-Diversity dengan nilai l = 2, artinya setiap kelompok *equivalence class* wajib memiliki paling sedikit dua nilai berbeda untuk setiap atribut sensitif.

Seluruh atribut quasi-identifier disertakan dalam konfigurasi, sementara *deposit*, *balance*, dan *default* dipilih sebagai atribut sensitif. ARX kemudian mengevaluasi seluruh kemungkinan kombinasi generalisasi untuk menentukan apakah dataset dapat memenuhi syarat l-diversity tanpa perlu perubahan drastis pada struktur datanya.

Pada proses ini, ARX menghasilkan 60 kombinasi transformasi generalisasi. Setiap kombinasi dievaluasi berdasarkan status anonimisasi, skor utilitas, dan tingkat risiko re-identifikasi. Berikut untuk demo pada ARX.

Demo dimulai dengan membuat *project* baru dan melakukan *import* data. Setelah itu dilakukan pengecekan tipe data. Dilanjutkan dengan pengubahan type pada bagan bagian kanan dengan format seperti yang telah dijelaskan pada pendahuluan yaitu age, job, dan education dengan quasi. Balance, Default, dan Deposit dengan sensitive. Untuk kolom lain menyesuaikan quasi seperti pada gambar 2.1 berikut.

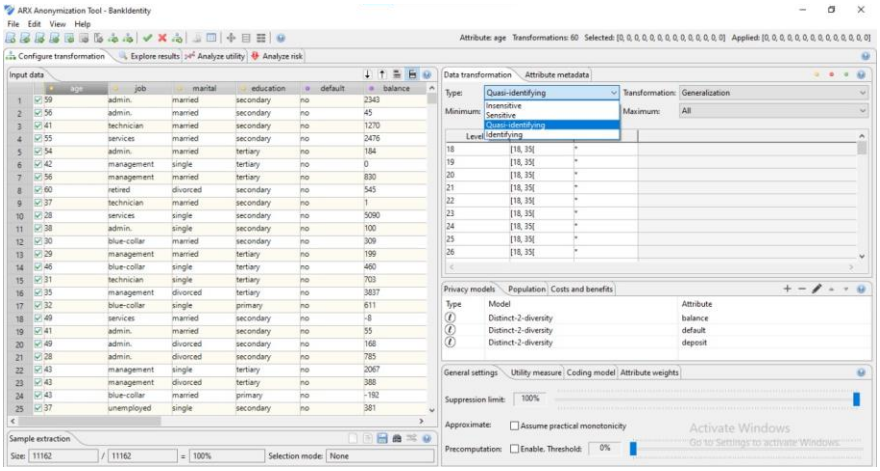

Gambar 2.1 Penentuan Type pada Kolom

Setelah itu dilakukan pembuatan *hierarchy* pada 3 kolom utama yaitu age, job, dan education yang tampak pada gambar 2.2.

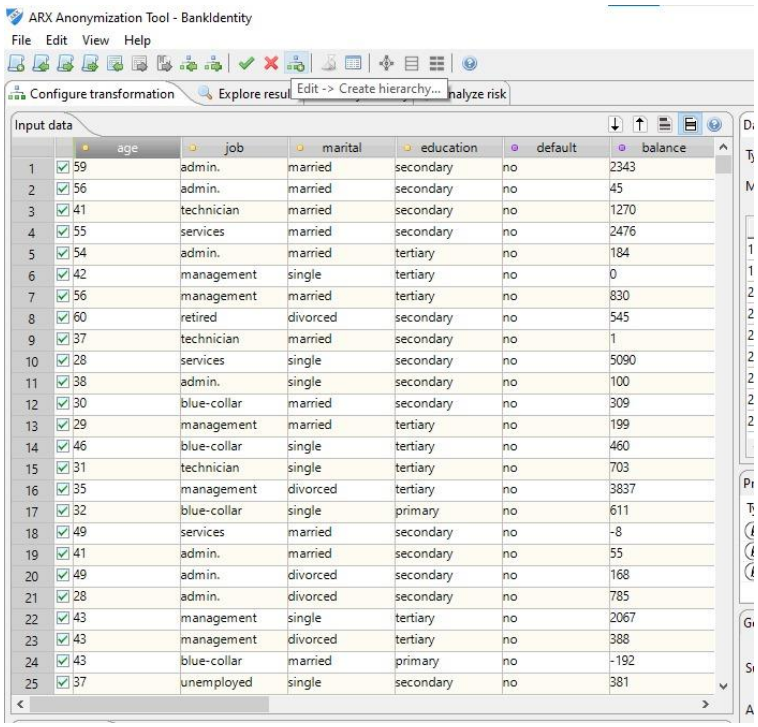

Gambar 2.2 Create Hierarchy

Dilanjutkan dengan pemilihan generalization hierarchy. Untuk kolom age menggunakan interval dengan *setting* pada gambar 2.3. Sedangkan untuk kolom job dan education menggunakan create ordering seperti pada gambar 2.4, lalu tambahkan level dengan melakuakn klik kanan hingga level 2 level setelahnya karena pemilihan l=2.

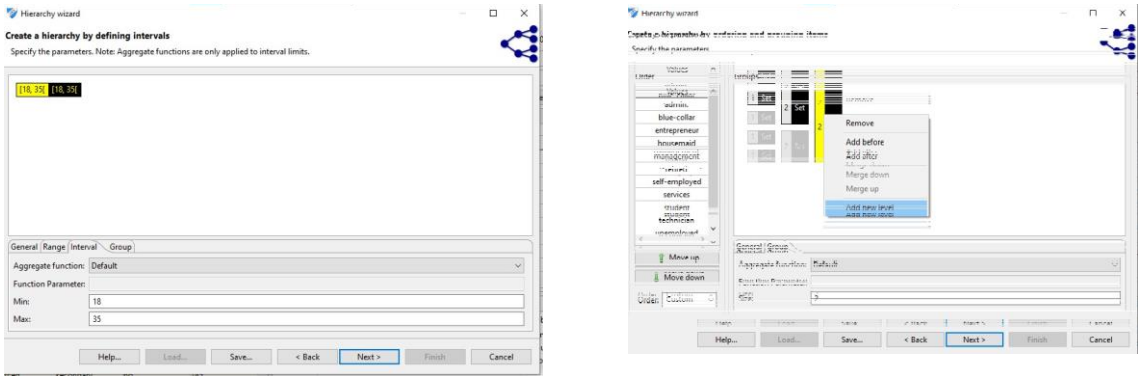

Gambar 2.3. Melakukan Setting Hierarchy

Setelah itu pada gambar 2.3, klik tabel Range dan pastikan format pemotongan sama seperti pada gambar 2.4 lalu klik next dan finish. Untuk hasil datanya dapat dilihat pada gambar 2.4

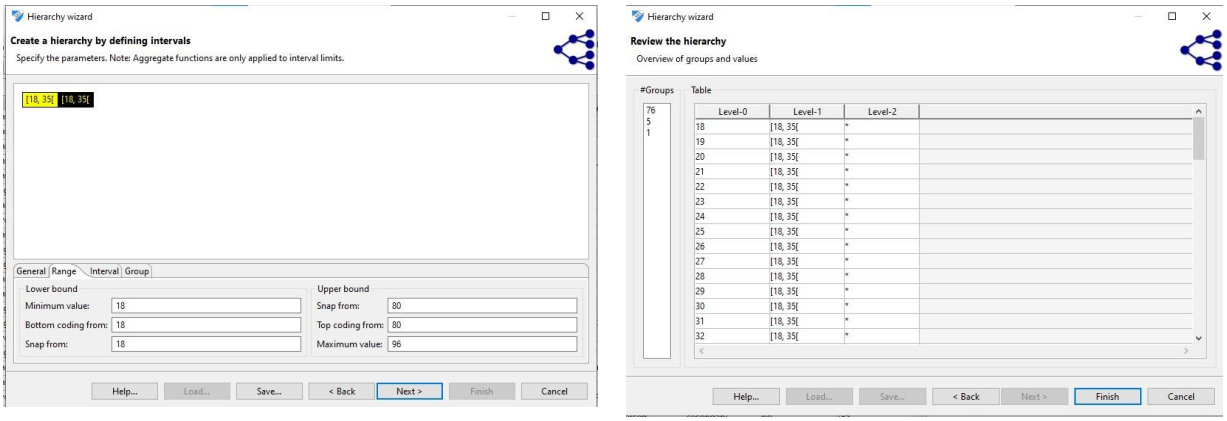

Gambar 2.4 Setting Lanjutan Hierarchy

Dilanjutkan dengan pengaturan suppresion untuk menghilangakn outlier hingga 100%. Lalu klik centang untuk menjalankan proses anonymization sehingga hasil akan tampak pada gambar 2.5 pada bagian kiri.

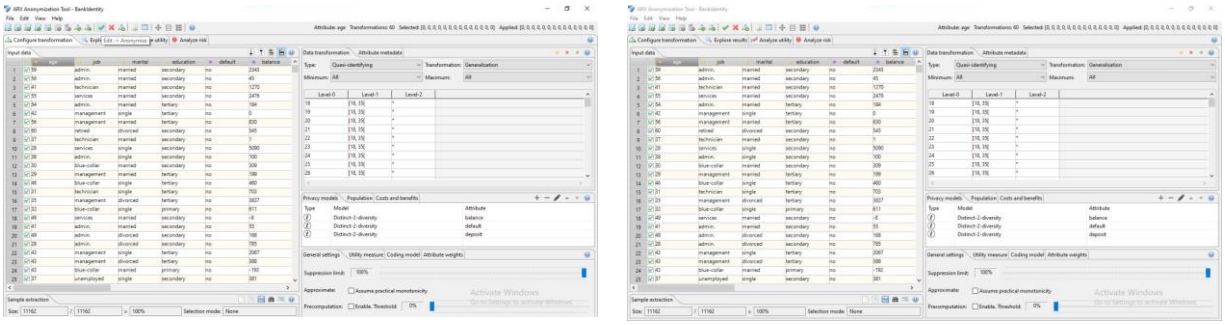

Gambar 2.5 Hasil Data L-Diversity

2.2 K-Anonymity

Penerapan k-anonymity dilakukan menggunakan perangkat lunak ARX Data Anonymization Tool. Pada tahapan ini, nilai k ditetapkan sebesar 5, yang berarti bahwa setiap kelompok atau *equivalence class* dalam dataset wajib berisi minimal lima record dengan kombinasi nilai quasi-identifier yang sama. Hal ini dimaksudkan untuk memastikan bahwa tidak ada individu yang dapat dibedakan dari setidaknya empat individu lainnya, sehingga risiko re-identifikasi dapat diminimalkan.

Sebelum proses anonimasi dijalankan, seluruh atribut diperiksa dan dikategorikan berdasarkan perannya. Atribut age, education, dan job ditetapkan sebagai quasi-identifier karena ketiganya berpotensi mengungkap identitas seseorang ketika digabungkan. Atribut lainnya ditetapkan sebagai insensitive attribute karena tidak secara langsung meningkatkan risiko re-identifikasi. Setelah pengaturan tipe data selesai, dataset kemudian dimasukkan ke ARX untuk dianalisis.

ARX kemudian mengevaluasi berbagai kemungkinan generalisasi nilai pada ketiga quasi-identifier tersebut. Setiap kombinasi generalisasi dievaluasi berdasarkan kemampuan memenuhi syarat k-anonymity, skor utilitas data, serta tingkat risiko re-identifikasi. Proses eksplorasi ini menghasilkan sejumlah transformasi, dan salah satu transformasi yang memenuhi syarat k=5 dipilih sebagai solusi akhir. Transformasi yang dipilih pada proses ini berada pada tingkat generalisasi sedang, terutama pada atribut education, sementara atribut age dan job tetap berada pada tingkat generalisasi minimal. Hal ini terjadi karena ARX berusaha mempertahankan utilitas data sebanyak mungkin sambil tetap memenuhi batas minimum k-anonymity.

Demo proses dilakukan dengan membuat project baru di ARX, mengimpor dataset, dan melakukan penyesuaian tipe atribut. Setelah itu, visualisasi heatmap pada menu Properties digunakan untuk membandingkan tingkat granularitas data sebelum dan sesudah generalisasi. Heatmap awal menunjukkan variasi warna yang lebih kompleks, menandakan tingginya detail data dan risiko re-identifikasi. Setelah generalisasi, heatmap tampak lebih homogen yang menunjukkan bahwa penyederhanaan nilai telah berhasil dilakukan agar k-anonymity terpenuhi. Proses dilanjutkan dengan pemilihan transformasi yang sepenuhnya memenuhi k=5 dan memiliki tingkat utilitas yang dapat diterima. Berikut langkah-langkah penerapan K-Anonymity pada ARX.

Pertama lakukan hal yang serupa seperti pada l-diversity yaitu membuat project yang baru lalu melakukan import data. Lalu pada kolom age, job, dan education pastikan dalam tipe quasi sedangkan kolom data yang lain tipe insensitive. Lalu gunaka suppresion 100 sama seperti quasi. Setelah itu klik tanda centang dan klik OK.

3. Hasil dan Analisis

3.1 Hasil dan Analisis Penerapan L-Diversity

Penerapan model Distinct l-Diversity dengan nilai l = 2 pada atribut sensitif *deposit*, *balance*, dan *default* menghasilkan temuan bahwa dataset telah memenuhi syarat privasi tanpa memerlukan generalisasi apa pun pada atribut quasi-identifier. ARX mengevaluasi 60 kemungkinan kombinasi transformasi, namun pada kondisi awal (generalization level 0 pada seluruh QI), dataset sudah memperoleh status ANONYMOUS untuk seluruh atribut sensitif.

Hal ini berarti bahwa setiap *equivalence class* yang terbentuk dari kombinasi QI memiliki setidaknya dua nilai berbeda untuk setiap atribut sensitif. Dengan demikian, meskipun kelompok identitas dapat terbentuk dengan granularitas tinggi, penyerang tidak dapat memastikan nilai sensitif seseorang secara pasti. Kondisi ini memenuhi dasar l-diversity untuk mencegah *homogeneity attack* dan *background knowledge attack*.

Dari sisi generalisasi, ARX menunjukkan bahwa seluruh quasi-identifier berada pada level **0**, artinya tidak ada penyederhanaan kategori, penggabungan nilai, ataupun bentuk transformasi lain. Hal ini juga tercermin pada skor utility di tab *Analyze Utility*, yang seluruhnya menunjukkan nilai maksimum (diwakili dengan bar berwarna biru penuh).

Selanjutnya, tab *Analyze Risk* menunjukkan bahwa risiko re-identifikasi berada pada level rendah. Hal ini terjadi karena l-diversity memaksa setiap kelompok identitas untuk memiliki variasi nilai sensitif yang memadai, meskipun kelompok itu sendiri tidak diperbesar melalui generalisasi. Dengan demikian, meskipun data tetap lengkap dan tidak mengalami kehilangan informasi, perlindungan terhadap atribut sensitif tetap terjaga.

Solusi optimal yang dipilih ARX adalah transformasi `[0, 0, 0, 0, ...]` tanpa generalisasi atau suppression. Skor information loss = 1.0000, menandakan tidak ada hilangnya informasi. Temuan ini memperlihatkan bahwa struktur data asli sudah cukup beragam sehingga dapat memenuhi l-diversity tanpa modifikasi tambahan. Berikut untuk dokumentasi hasil dari l-diversity pada Gambar 3.1.

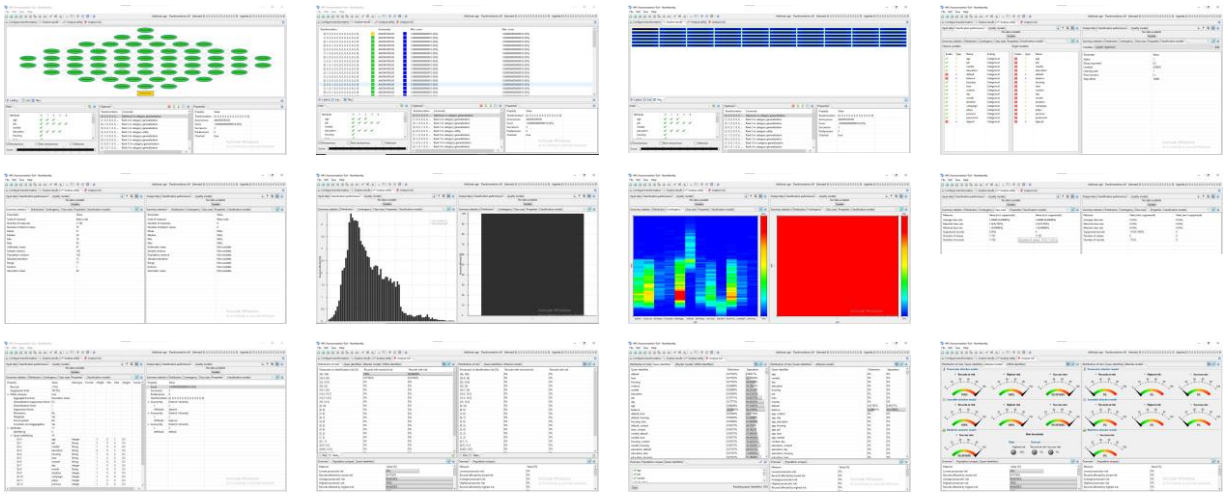

Gambar 3.1 Hasil Seluruh L-Diversity

3.2 Hasil dan Analisis Penerapan K-Anonymity

Penerapan k-anonymity dengan nilai k=5 menghasilkan dataset yang sepenuhnya memenuhi persyaratan anonimisasi. Transformasi yang ditetapkan ARX menunjukkan bahwa kombinasi quasi-identifier age, education, dan job telah disederhanakan sedemikian rupa sehingga setiap kombinasi muncul pada minimal lima individu. Salah satu perubahan paling signifikan terlihat pada atribut education yang harus digeneralisasi ke tingkat yang lebih tinggi agar seluruh kelompok memenuhi batas minimal k. Sementara itu, atribut age dan job relatif tetap pada level generalisasi rendah karena distribusi datanya sudah cukup merata.

Visualisasi heatmap setelah generalisasi menunjukkan penyederhanaan kategori dengan warna yang lebih seragam, yang menandakan bahwa detail informasi yang sebelumnya terlalu spesifik telah berhasil dikurangi. Hal ini berdampak langsung pada penurunan risiko re-identifikasi.

Analisis risiko pada menu *Analyze Risk* menunjukkan perbaikan signifikan setelah penerapan generalisasi. Nilai *average prosecutor risk* turun dibandingkan kondisi awal, dan *highest prosecutor risk* juga turun dari 100% menjadi hanya 20%. Artinya, tidak ada lagi individu yang unik berdasarkan kombinasi quasi-identifier tersebut, sehingga risiko tertinggi kini jauh lebih rendah dan sesuai dengan standar k-anonymity. Selain itu, jumlah *sample uniques* menjadi nol, yang berarti dataset tidak lagi memiliki individu dengan kombinasi informasi yang unik.

Secara keseluruhan, penerapan k-anonymity dengan k=5 berhasil mengurangi risiko re-identifikasi secara signifikan tanpa menyebabkan hilangnya utilitas data yang berlebihan. ARX mampu menemukan titik keseimbangan antara perlindungan privasi dan pemeliharaan kualitas data. Hasil ini menunjukkan bahwa metode k-anonymity dapat diterapkan secara efektif pada dataset bank marketing dengan konfigurasi quasi-identifier yang digunakan. Berikut untuk dokumentasi hasil dari l-diversity pada Gambar 3.2.

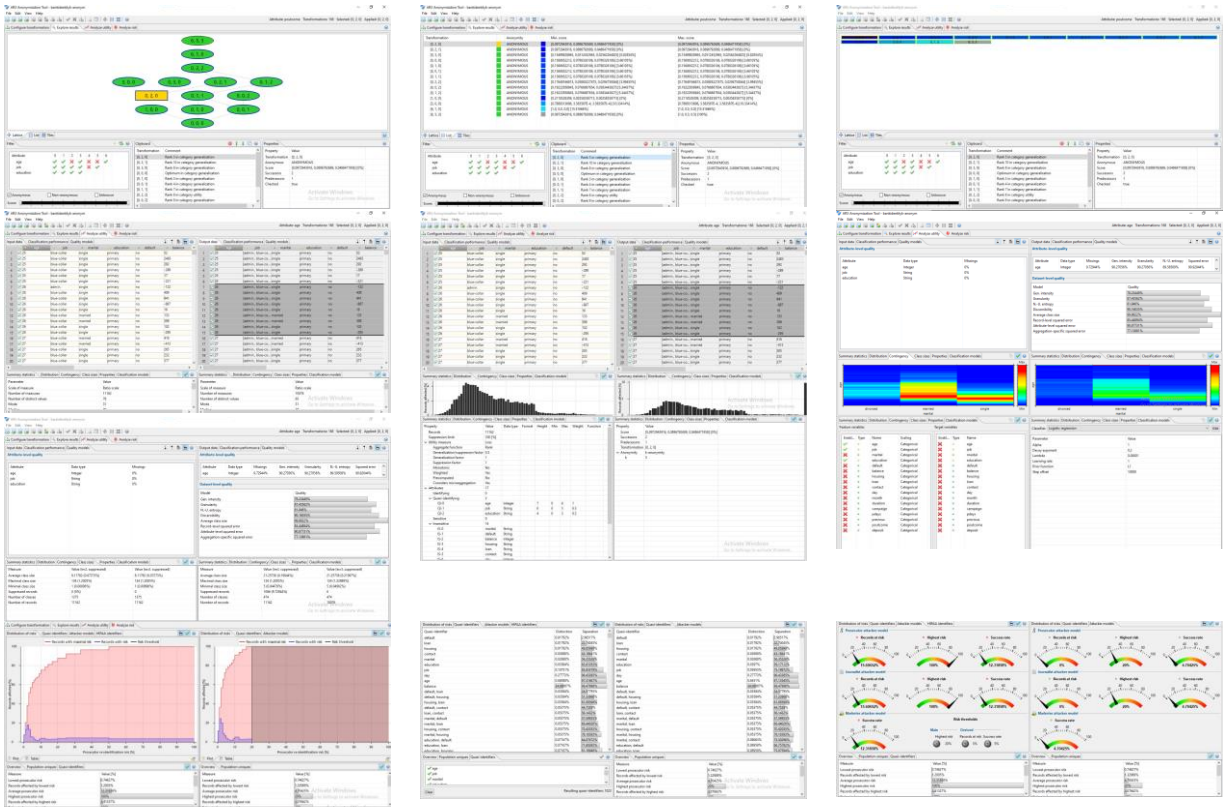

Gambar 3.2 Hasil K-Anonymity

4. Perbandingan l-Diversity dan k-Anonymity

Perbandingan antara l-diversity dan k-anonymity dilakukan untuk memahami bagaimana kedua model privasi tersebut bekerja dalam konteks dataset yang sama, serta bagaimana masing-masing metode memengaruhi struktur generalisasi, tingkat risiko, dan utilitas data. Kedua metode ini memiliki tujuan yang sama yaitu mengurangi risiko re-identifikasi, namun mekanisme dan dampaknya terhadap data berbeda secara fundamental.

Pada penerapan l-diversity dengan nilai l = 2, ARX menemukan bahwa dataset telah memenuhi seluruh persyaratan privasi tanpa memerlukan generalisasi apa pun pada quasi-identifier. Seluruh quasi-identifier tetap pada level 0, dan information loss berada pada nilai maksimum (1.0), yang berarti tidak ada perubahan pada struktur data asli. Hal ini dapat terjadi karena distribusi nilai sensitif pada atribut deposit, balance, dan default sudah cukup beragam, sehingga setiap *equivalence class* secara alami memiliki lebih dari satu nilai sensitif dan memenuhi syarat l-diversity. Dengan demikian, meskipun tidak dilakukan generalisasi, risiko homogeneity attack tetap dapat ditekan.

Sebaliknya, pada penerapan k-anonymity dengan nilai k = 5, ARX menemukan bahwa dataset belum memenuhi syarat anonimitas apabila seluruh quasi-identifier berada pada level generalisasi awal. Terdapat sejumlah *equivalence class* yang memiliki ukuran kurang dari lima, sehingga kombinasi atribut age, education, dan job masih dapat digunakan untuk membedakan individu secara unik. Untuk mengatasi hal tersebut, ARX menerapkan generalisasi pada atribut education hingga level 2, sementara age dan job tetap berada pada level dasar. Transformasi ini diperlukan agar tidak ada lagi kelompok dengan jumlah anggota kurang dari lima dan seluruh kombinasi quasi-identifier dapat memenuhi ketentuan $k \geq 5$.

Dalam hal risiko re-identifikasi, l-diversity memberikan perlindungan terutama terhadap attribute disclosure, namun tidak secara langsung meningkatkan ukuran kelompok identitas. Sebaliknya, k-anonymity berfokus pada perlindungan identitas individu melalui pembesaran kelompok, sehingga efektif dalam menurunkan risiko re-identifikasi langsung. Hal ini terlihat dari penurunan highest prosecutor risk dari 100% menjadi 20% setelah k-anonymity diterapkan.

Dari sisi utilitas data, l-diversity memiliki tingkat utilitas yang paling tinggi karena tidak melakukan generalisasi sama sekali, sedangkan k-anonymity mengalami sedikit penurunan utilitas akibat generalisasi pada satu atribut. Namun, generalisasi yang diterapkan tetap tergolong minimal sehingga struktur data masih cukup stabil untuk keperluan analisis lebih lanjut.

Perbedaan utama antara kedua metode ini menunjukkan bahwa l-diversity lebih efektif ketika dataset sudah memiliki keragaman nilai sensitif yang tinggi sejak awal, sedangkan k-anonymity diperlukan ketika distribusi quasi-identifier terlalu spesifik dan menghasilkan kelompok identitas yang terlalu kecil. Dalam eksperimen ini, kedua metode saling melengkapi dan memberikan

gambaran yang jelas tentang bagaimana tingkat privasi dan utilitas dapat dipengaruhi oleh pendekatan anonimisasi yang berbeda. Berikut tabel perbandingan kedua metrik tersebut.

Aspek	l-Diversity (l=2)	k-Anonymity (k=5)
Generalisasi	Tidak ada, level 0	Diperlukan pada education (level 2)
Quasi-Identifier	age, job, education	age, job, education
Atribut sensitif	deposit, balance, default	tidak digunakan
Risiko sebelum	rendah	sangat tinggi
Risiko sesudah	tetap rendah	turun menjadi rendah
Highest Risk	tidak berubah signifikan	turun dari 100% → 20%
Sample uniques	ada, tetapi l-diversity tidak bergantung padanya	0 setelah generalisasi
Information loss	0%	sedikit meningkat
Utility	sangat tinggi	tetap tinggi, sedikit turun
Kelebihan utama	melindungi attribute disclosure	melindungi identity disclosure
Keterbatasan	tidak memperbesar equivalence class	tidak melindungi dari attribute disclosure

5. Kesimpulan

Berdasarkan seluruh rangkaian eksperimen menggunakan ARX Data Anonymization Tool, dapat disimpulkan bahwa baik l-diversity maupun k-anonymity memberikan kontribusi penting dalam perlindungan privasi pada dataset. Penerapan l-diversity dengan nilai l = 2 pada atribut deposit, balance, dan default menunjukkan bahwa dataset memiliki keragaman nilai sensitif yang cukup kuat sejak awal, sehingga metode ini dapat dipenuhi tanpa generalisasi tambahan. Hal ini menjadi indikasi bahwa risiko homogeneity attack relatif kecil dan struktur data asli dapat dipertahankan sepenuhnya.

Sebaliknya, pada penerapan k-anonymity dengan nilai k = 5, ditemukan bahwa dataset belum memenuhi syarat anonimitas pada kondisi awal karena masih terdapat banyak kombinasi quasi-identifier yang unik atau memiliki jumlah anggota terlalu sedikit. Untuk mencapai k=5, ARX melakukan generalisasi pada atribut tertentu yaitu education, sementara atribut age dan job tetap terjaga pada bentuk aslinya. Transformasi ini berhasil menurunkan risiko re-identifikasi secara signifikan dan menghilangkan seluruh pola unik dalam dataset, meskipun menyebabkan sedikit penurunan utilitas data.

Hasil akhir eksperimen memperlihatkan bahwa kedua metode anonimisasi memiliki keunggulan masing-masing. L-Diversity memberikan stabilitas utilitas data yang tinggi tanpa memerlukan transformasi apa pun, sedangkan k-anonymity menawarkan perlindungan yang kuat terhadap identifikasi ulang meskipun memerlukan generalisasi tambahan. Kombinasi analisis dari kedua metode ini memberikan pemahaman yang lebih komprehensif mengenai bagaimana privasi dan utilitas dapat diseimbangkan pada dataset finansial seperti bank marketing. Temuan ini diharapkan dapat menjadi dasar untuk eksperimen lanjutan serta panduan dalam memilih teknik anonimisasi yang paling sesuai dengan kebutuhan penelitian maupun implementasi praktis.